

运筹学与最优化方法作业1

陳日康 信息与计算科学 22336049

1. 设 $C \subseteq \mathbb{R}^n$ 为一个凸集。证明：对任意 k 个向量 $x_1, \dots, x_k \in C$ ，以及 $\theta_1, \dots, \theta_k \in \mathbb{R}$ 满足 $\theta_1 + \dots + \theta_k = 1, \theta_i \geq 0$ ，都有 $\theta_1 x_1 + \dots + \theta_k x_k \in C$ 。（注：凸集的定义要求此式在 $k = 2$ 时成立，这里需要证明对任意 $k \geq 2$ 都成立）

证明：当 $k = 2$ ，若 $x_1, x_2 \in C$ ，且 $\theta_1 + \theta_2 = 1, \theta_1, \theta_2 \geq 0$ ，则 $\theta_1 x_1 + \theta_2 x_2 \in C$ 成立。

当 $k = m$ 时，对任意 $x_1, \dots, x_m \in C, \theta_1 + \dots + \theta_m = 1, \theta_i \geq 0$ ，有 $\sum_{i=1}^m \theta_i x_i \in C$ ，

当 $k = m + 1$ 时，设 $x_1, \dots, x_{m+1} \in C, \theta_1 + \dots + \theta_{m+1} = 1, \theta_i \geq 0$ 。

设 $\alpha = \theta_1 + \dots + \theta_m = 1 - \theta_{m+1} \in [0, 1]$ ，定义 $y = \frac{1}{\alpha} \sum_{i=1}^m \theta_i x_i$ 。当 $\alpha = 0$ ，即 $\theta_{m+1} = 1$ ，其余全为 0，此时 $\sum \theta_i x_i = x_{m+1} \in C$ 成立。

若 $\alpha > 0$ ，构造向量 $y = \frac{\theta_1}{\alpha} x_1 + \frac{\theta_2}{\alpha} x_2 + \dots + \frac{\theta_m}{\alpha} x_m$ ，其中每个系数 $\frac{\theta_i}{\alpha} \geq 0$ ，系数和是 $\frac{\theta_1 + \dots + \theta_m}{\alpha} = \frac{\alpha}{\alpha} = 1$ ，所以 y 是 $x_1, \dots, x_m$ 的凸组合，由归纳假设有 $y \in C$ 。

又因为 $y \in C, x_{m+1} \in C$ ，且 $\theta_1 x_1 + \dots + \theta_m x_m + \theta_{m+1} x_{m+1} = \alpha y + \theta_{m+1} x_{m+1}$ ，这是 y 和 x_{m+1} 的凸组合 ($\alpha + \theta_{m+1} = 1$)，由凸性有 $\alpha y + \theta_{m+1} x_{m+1} \in C$ 。

由数学归纳法可知，对任意 $k \geq 2$ ，满足凸组合条件的 $x_1, \dots, x_k \in C$ ，都有 $\sum_{i=1}^k \theta_i x_i \in C$ 。

2. 证明：集合 S 的凸包是所有包含 S 的凸集的交。

证：设 $S \subseteq \mathbb{R}^n$ 是任意集合。定义其凸包 $\text{conv}(S)$ 为包含 S 的所有凸集的交集，即包含 S 的所有凸集的交。记所有包含 S 的凸集组成的族为 $\mathcal{C}$ ，则要证明 $\text{conv}(S) = \bigcap_{C \in \mathcal{C}} C$ 。

$\text{conv}(S)$ 本身是一个凸集，且显然包含 S 。由于它是最小的这样的凸集，因此对于任意 $C \in \mathcal{C}$ ，都有 $\text{conv}(S) \subseteq C$ 。因此 $\text{conv}(S)$ 包含在所有这些凸集的交中，即 $\text{conv}(S) \subseteq \bigcap_{C \in \mathcal{C}} C$ 。

设 x 是属于所有包含 S 的凸集的交的一个点，即 $x \in \bigcap_{C \in \mathcal{C}} C$ 。由于 $\text{conv}(S)$ 也是包含 S 的凸集，故其本身属于 $\mathcal{C}$ ，因此 $x \in \text{conv}(S)$ ，所以 $\bigcap_{C \in \mathcal{C}} C \subseteq \text{conv}(S)$ 。

综上，两个集合互相包含，得 $\text{conv}(S) = \bigcap_{C \in \mathcal{C}} C$ ，即集合 S 的凸包正是所有包含它的凸集的交集，亦即包含 S 的最小凸集。

3. 设 $C \subseteq \mathbb{R}^n$ 为二次不等式的解集, 即 $C = \{x \in \mathbb{R}^n \mid x^T A x + b^T x + c \leq 0\}$, 其中 $A \in S^n$, $b \in \mathbb{R}^n$, $c \in \mathbb{R}$ 。证明: 若 $A \succeq 0$ (即 A 是半正定矩阵), 则 C 是凸集。

证明: 根据凸集定义, 若对任意 $x_1, x_2 \in C$ 及 $\lambda \in [0, 1]$, 有 $\lambda x_1 + (1 - \lambda)x_2 \in C$, 则集合 C 是凸集。

设 $x_1, x_2 \in C$, $\lambda \in [0, 1]$, 考虑 $\lambda x_1 + (1 - \lambda)x_2$, 则

$$f(\lambda x_1 + (1 - \lambda)x_2) = [\lambda x_1 + (1 - \lambda)x_2]^T A [\lambda x_1 + (1 - \lambda)x_2] + b^T [\lambda x_1 + (1 - \lambda)x_2] + c,$$

$$\text{展开得: } \lambda^2 x_1^T A x_1 + 2\lambda(1 - \lambda)x_1^T A x_2 + (1 - \lambda)^2 x_2^T A x_2 + \lambda b^T x_1 + (1 - \lambda)b^T x_2 + c$$

由于 A 对称且半正定, 利用二次型的凸性, 可得:

$$\leq \lambda(x_1^T A x_1 + b^T x_1 + c) + (1 - \lambda)(x_2^T A x_2 + b^T x_2 + c)。$$

因为 $x_1, x_2 \in C$, 所以 $x_1^T A x_1 + b^T x_1 + c \leq 0$, $x_2^T A x_2 + b^T x_2 + c \leq 0$, 故有:
 $\lambda x_1 + (1 - \lambda)x_2 \in C$ 。

因此, 当 $A \succeq 0$ 时, 集合 $C = \{x \in \mathbb{R}^n \mid x^T A x + b^T x + c \leq 0\}$ 是凸集。

4. 确定以下函数的凹凸性:

$$(a) f(x) = \sum_{i=1}^n x_i \ln x_i, x_i \in \mathbb{R}_{++}, i = 1, \dots, n;$$

$$(b) f(x_1, x_2) = x_1 x_2, (x_1, x_2) \in \mathbb{R}_{++}^2;$$

$$(c) f(x_1, x_2) = x_1/x_2, (x_1, x_2) \in \mathbb{R}_{++}^2。$$

解:

$$(a). \text{函数的一阶导数为 } \frac{\partial f}{\partial x_i} = \ln x_i + 1, \text{二阶导数为 } \frac{\partial^2 f}{\partial x_i^2} = \frac{1}{x_i}。 \text{由于 } x_i \in \mathbb{R}_{++}, \text{所以 } \frac{1}{x_i} > 0。$$

因此二阶偏导数矩阵是正定的, 函数是严格凸的。

$$(b). \text{对于函数 } f(x_1, x_2), \text{计算一阶偏导数 } \frac{\partial f}{\partial x_1} = x_2 \text{ 和 } \frac{\partial f}{\partial x_2} = x_1, \text{二阶偏导数为 } \frac{\partial^2 f}{\partial x_1^2} = 0, \\ \frac{\partial^2 f}{\partial x_2^2} = 0, \frac{\partial^2 f}{\partial x_1 x_2} = 1。$$

二阶偏导数矩阵为 $\begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$, 矩阵既不是正定的也不是负定的, 所以函数非凸非凹。

$$(c). \text{计算一阶偏导数, } \frac{\partial f}{\partial x_1} = \frac{1}{x_2} \text{ 和 } \frac{\partial f}{\partial x_2} = -\frac{x_1}{x_2^2}, \text{二阶偏导数为 } \frac{\partial^2 f}{\partial x_1^2} = 0, \frac{\partial^2 f}{\partial x_2^2} = \frac{2x_1}{x_2^3}, \\ \frac{\partial^2 f}{\partial x_1 x_2} = \frac{1}{x_2^2}。$$

二阶偏导数矩阵为 $\begin{pmatrix} 0 & -\frac{1}{x_2^2} \\ -\frac{1}{x_2^2} & \frac{2x_1}{x_2^3} \end{pmatrix}$ ，矩阵既不是正定也不是负定的，因此函数非凸非凹。

5. 推导线性规划问题的对偶问题和 KKT 条件：

$$\begin{aligned} \min_x \quad & C^T x \\ \text{s. t.} \quad & Gx \leq h, \\ & Ax = b \end{aligned}$$

解：对于不等式约束 $Gx \leq h$ ，引入拉格朗日乘子 $\lambda \in \mathbb{R}^p$ ，要求 $\lambda \geq 0$ ，对于等式约束 $Ax = b$ ，引入乘子 $\nu \in \mathbb{R}^m$ 。

得到拉格朗日函数： $\mathcal{L}(x, \lambda, \nu) = c^T x + \lambda^T (Gx - h) + \nu^T (Ax - b)$ ，

展开整理得： $\mathcal{L}(x, \lambda, \nu) = (c + G^T \lambda + A^T \nu)^T x - \lambda^T h - \nu^T b$ 。

定义对偶函数，即对 x 取极小值， $g(\lambda, \nu) = \inf_x \mathcal{L}(x, \lambda, \nu)$ 。

如果 $c + G^T \lambda + A^T \nu \neq 0$ ，则 $\mathcal{L}(x, \lambda, \nu)$ 关于 x 是关于无界线性函数，所以必须要求 $c + G^T \lambda + A^T \nu = 0$ ，

此时 $\mathcal{L}(x, \lambda, \nu) = -\lambda^T h - \nu^T b$ 与 x 无关，极小值就是常数。

于是对偶问题就是最大化这个下界： $\max_{\lambda, \nu} -\lambda^T h - \nu^T b \quad \text{s. t.} \quad G^T \lambda + A^T \nu + c = 0, \lambda \geq 0$

KKT 条件： $Gx \leq h, Ax = b, \lambda \geq 0, c + G^T \lambda + A^T \nu = 0, \lambda_i (Gx - h)_i = 0 \quad \forall i$ 。

6. 推导以下问题的对偶问题： $\min_x \frac{1}{2} \|x - x_0\|_2^2 + \sum_{i=1}^N \|A_i x + b_i\|_2$ ，其中 $A_i \in \mathbb{R}^{m_i \times n}$ ，

$B_i \in \mathbb{R}^{m_i}$ ，且 $x_0 \in \mathbb{R}^n$ 。（提示：引入新的变量 $y_i \in \mathbb{R}^{m_i}$ 以及等式约束 $y_i = A_i x + b_i$ ，将原无约束优化问题转化为约束优化问题后，再推导其对偶问题。）

解：先转化为约束优化问题，引入变量 y_i 及约束 $y_i = A_i x + b_i$ ，原问题变为：

$$\min_{x, \{y_i\}} \frac{1}{2} \|x - x_0\|_2^2 + \sum_{i=1}^N \|y_i\|_2, \text{ s.t. } y_i = A_i x + b_i。$$

加入拉格朗日乘子 $\lambda_i \in \mathbb{R}^{m_i}$ ，拉格朗日函数为

$$\mathcal{L}(x, y_i, \{\lambda_i\}) = \frac{1}{2} \|x - x_0\|_2^2 + \sum_{i=1}^N \|y_i\|_2 + \lambda_i^T (A_i x - b_i - y_i)。$$

对偶函数为 $g(\{\lambda_i\}) = \inf_{x, \{y_i\}} \mathcal{L}(x, y_i, \lambda_i)$ ，先对 y_i 求极小： $\inf_{y_i} (\|y_i\|_2 - \lambda_i^T y_i)$ 。极小值是有限当且仅当

$\|\lambda_i\|_2 \leq 1$ ，否则 $g(\lambda_i) = -\infty$ 。

在满足上述约束下，最小值为： $y = \begin{cases} 0, & \text{当 } \|\lambda_i\|_2 \leq 1 \\ -\infty, & \text{else} \end{cases}$

然后对 x 求极小： $\inf_x \left(\frac{1}{2} \|x - x_0\|_2^2 + \sum_{i=1}^N \lambda_i^\top A_i x \right)$

这部分是一个标准的凸二次优化，其解析极小值可以通过梯度为零求得：

$\nabla_x = x - x_0 + \sum_{i=1}^N A_i^\top \lambda_i = 0$ ，解得最优值 $x^* = x_0 - \sum_{i=1}^N A_i^\top \lambda_i$ ，代回得：

$$\inf_x = -\frac{1}{2} \left\| \sum_{i=1}^N A_i^\top \lambda_i \right\|_2^2 + \left(\sum_{i=1}^N \lambda_i^\top A_i x_0 \right),$$

对偶函数最终表达式为： $g(\{\lambda_i\}) = \frac{1}{2} \left\| \sum_{i=1}^N A_i^\top \lambda_i \right\|_2^2 + \sum_{i=1}^N \lambda_i^\top (A_i x_0 + b_i)$ 。

所以对偶问题为 $\max_{\lambda_i} -\frac{1}{2} \left\| \sum_{i=1}^N A_i^\top \lambda_i \right\|_2^2 + \sum_{i=1}^N \lambda_i^\top (A_i x_0 + b_i)$ s. t. $\|\lambda_i\|_2 \leq 1, \forall i = 1, \dots, N$ 。